

奇异值分解

Singular Value Decomposition

西安交通大学管理学院
信息管理与电子商务系
智能决策与机器学习研究中心
刘佳鹏

思考下列问题

设 $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$, $\mathbf{x} = (\sqrt{2}, 0)^T$, 得到 $\mathbf{Ax} = (2\sqrt{2}, -\sqrt{2})^T$ 。如何理解该矩阵乘法呢?

矩阵乘法的理解

- ▶ 矩阵乘法的本质是线性变换！常见的简单变换包括
- ▶ (1) **拉伸变换**，包括：
水平拉伸：

$$\mathbf{A} = \begin{bmatrix} k & 0 \\ 0 & 1 \end{bmatrix}$$

例如

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

垂直拉伸：

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & k \end{bmatrix}$$

例如

$$\begin{bmatrix} 1 & 0 \\ 0 & 0.5 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

矩阵乘法的理解

- ▶ (2) **翻转变换**, 亦称**反射变换**, 包括:
关于X轴翻转:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

例如

$$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

关于Y轴翻转:

$$\mathbf{A} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

例如

$$\begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

矩阵乘法的理解

- 关于 $Y=X$ 翻转:

$$\mathbf{A} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

例如

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

关于 $Y=-X$ 翻转:

$$\mathbf{A} = \begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix}$$

例如

$$\begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

矩阵乘法的理解

- ▶ 关于原点翻转:

$$\mathbf{A} = \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}$$

例如

$$\begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

矩阵乘法的理解

► (3) 旋转变换:

关于原点旋转 θ° ($\theta > 0$ 逆时针旋转, $\theta < 0$ 顺时针旋转):

$$\mathbf{A} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

例如, 顺时针旋转 90° ,

$$\mathbf{A} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad \text{有} \quad \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

矩阵乘法的理解

- ▶ (4) 投影变换, 包括
向X轴投影:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

例如

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

向Y轴投影:

$$\mathbf{A} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

例如

$$\begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

回到开篇的问题

$$\mathbf{Ax} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} 2\sqrt{2} \\ -\sqrt{2} \end{bmatrix}$$

- ▶ 如何理解 $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$ 对应的线性变换?
- ▶ \mathbf{A} 是一系列简单线性变换的组合!

回到开篇的问题

- ▶ 如何找出 $A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$ 背后对应的一系列简单线性变换呢？
- ▶ 这需要用到线性代数里的特征值和对角化等概念，在使用这些概念之前，我们先给出 A 分解得到的结果

$$A = PDP^{-1}$$

$$\text{其中 } P = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}, D = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, P^{-1} = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$$

回到开篇的问题

- 矩阵 $P = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$ 和 $P^{-1} = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$ 可以进一步分解为

$$P = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$$

分别表示“关于Y轴翻转”和“逆时针旋转45度”这两种简单线性变换的复合操作

$$P^{-1} = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

分别表示“顺时针旋转45度”和“关于Y轴翻转”这两种简单线性变换的复合操作

回到开篇的问题

- 因此, $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$ 可以分解为五个简单线性变换的复合操作

$$\mathbf{A} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

回到开篇的问题

- ▶ 因此线性变换 \mathbf{A} 施加在点 $\mathbf{x} = (\sqrt{2}, 0)^T$ 的变换可以分解为如下步骤：
- ▶ (1) $\mathbf{P}^{-1}\mathbf{x} = (-1, 1)^T$ ：将点 \mathbf{x} 关于Y轴翻转得到 $(-\sqrt{2}, 0)^T$ ，然后再顺时针旋转 45 度得到 $(-1, 1)^T$ ；
- ▶ (2) $\mathbf{DP}^{-1}\mathbf{x} = (-3, 1)^T$ ：将步骤 (1) 中得到的点 $(-1, 1)^T$ 进行水平拉伸得到 $(-3, 1)^T$ ；
- ▶ (3) $\mathbf{PDP}^{-1}\mathbf{x} = (2\sqrt{2}, -\sqrt{2})^T$ ：将步骤 (2) 中得到的点 $(-3, 1)^T$ 逆时针旋转 45 度得到 $(-2\sqrt{2}, -\sqrt{2})^T$ ，然后再关于Y轴翻转得到 $(2\sqrt{2}, -\sqrt{2})^T$ 。
- ▶ 注：上述变换中的步骤 (1) 和 (3) 只是一些翻转、旋转变换，没有改变向量的长度，而步骤 (2) 中的变换改变了向量的长度。

回到开篇的问题

- ▶ 通过上述例子，我们可以看出，如果对一个矩阵 \mathbf{A} 可以实施上述分解，那我们就能直观理解其背后包含的简单变换。
- ▶ 那么现在问题就变成了：（1）所有的矩阵 \mathbf{A} 都可以进行这样的分解吗？（2）如果矩阵 \mathbf{A} 可以分解，那么该如何进行实施这样的分解呢？
- ▶ 要回答上述问题，需要用到我们在线性代数课程中学过的矩阵对角化的知识。

矩阵对角化

- ▶ 设 A, B 都是 n 阶方阵, 如果存在一个 n 阶可逆方阵 P , 使得

$$P^{-1}AP = B,$$

则称 A 相似于 B 或 A 与 B 相似, 记作 $A \sim B$, 并称由 A 到 $B = P^{-1}AP$ 的变换为一个相似变换。如果 A 与一个对角矩阵相似, 则称 A 可相似对角化, 简称为 A 可对角化。

- ▶ 因为 $P^{-1}AP = B$, 所以 $A = PBP^{-1}$ 。
 - ▶ 利用该分解可以简化计算 A^n : $A^n = PB^nP^{-1}$ 。

矩阵对角化

- ▶ 问题：所有的矩阵都可以对角化吗？
- ▶ 答：不是的，要求矩阵必须是方阵，同时要满足以下充要条件。
- ▶ （矩阵可对角化的充要条件1） n 阶方阵 \mathbf{A} 可对角化的充要条件是 \mathbf{A} 有 n 个线性无关的特征向量。
- ▶ （矩阵可对角化的充要条件2） n 阶方阵 \mathbf{A} 可对角化的充要条件是 \mathbf{A} 的每个特征值的几何重数都等于它的代数重数。

矩阵对角化

- ▶ 虽然不是所有的矩阵都可以对角化，但有一类矩阵一定可以对角化，这就是实对称矩阵。
- ▶ 性质1：实对称矩阵的特征值都是实数。
- ▶ 性质2：设 λ_1, λ_2 是实对称矩阵 \mathbf{A} 的相异特征值， \mathbf{x}_1 和 \mathbf{x}_2 分别是与 λ_1 和 λ_2 对应的特征向量，则 \mathbf{x}_1 与 \mathbf{x}_2 正交。
- ▶ 性质3：设 λ 为实对称矩阵 \mathbf{A} 的任一特征值，则 λ 的几何重数与其代数重数必相等。

矩阵对角化

- ▶ 根据上述性质，我们可以用单位正交矩阵使实对称矩阵 \mathbf{A} 对角化，即求单位正交矩阵 \mathbf{P} ，使 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ 成为对角矩阵。
- ▶ 为此，只需对 n 阶实对称矩阵 \mathbf{A} 的每个特征值 λ_i 取方程组 $(\lambda_i \mathbf{I} - \mathbf{A})\mathbf{x} = 0$ 的正交化单位化的基础解系（即特征子空间 \mathbf{V}_{λ_i} 的一个标准正交基），此即属于特征值 λ_i 的正交化单位化的特征向量。
- ▶ 将所有这样的特征向量放在一起，由性质3可知，此向量组共有 n 个向量，而且它们是两两正交的。
- ▶ 事实上，若其中的两个向量分别属于 \mathbf{A} 的两个不同特征值，则由性质2可知它们是正交的；若其中的两个向量属于 \mathbf{A} 的同一特征值，则由前面的取法可知它们也是正交的。

矩阵对角化

- ▶ 由上可知, 对实对称矩阵 \mathbf{A} , 求正交矩阵 \mathbf{P} , 使 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ 成对角矩阵的步骤是:
- ▶ **步骤1:** 求出 \mathbf{A} 的全部特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$;
- ▶ **步骤2:** 对 \mathbf{A} 的每个特征值 λ_i , 求出方程组

$$(\lambda_i \mathbf{I} - \mathbf{A})\mathbf{x} = 0$$

的一个基础解系 (即特征子空间 \mathbf{V}_{λ_i} 的一个基);

矩阵对角化

- ▶ **步骤3:** 对每个特征值 λ_i , 将特征子空间 V_{λ_i} 的基中的向量先正交化, 再单位化 (如果 λ_i 为单特征值或 V_{λ_i} 的基中的向量已是正交向量组, 则只需单位化), 从而得到 A 的 n 个标准正交的特征向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$;
- ▶ **步骤4:** 令矩阵 $P = [\mathbf{e}_1 \ \mathbf{e}_2 \ \cdots \ \mathbf{e}_n]$, 则 P 为正交矩阵, 且有

$$P^{-1}AP = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n),$$

其中 P 的第 j 列 \mathbf{e}_j 是属于特征值 λ_j 的特征向量,
 $j = 1, 2, \dots, n$ 。

矩阵对角化

► 例1: 设实对称矩阵

$$\mathbf{A} = \begin{bmatrix} 2 & -2 & 0 \\ -2 & 1 & -2 \\ 0 & -2 & 0 \end{bmatrix}$$

求一个正交矩阵 \mathbf{P} , 使 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ 成对角矩阵。

矩阵对角化

► 例2: 设实对称矩阵

$$\mathbf{A} = \begin{bmatrix} 2 & 2 & -2 \\ 2 & 5 & -4 \\ -2 & -4 & 5 \end{bmatrix}$$

求一个正交矩阵 \mathbf{P} , 使 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ 成对角矩阵。

矩阵对角化

- ▶ **酉矩阵**：对于实对称矩阵 A ，如果我们采用 n 个标准正交的特征向量构成矩阵 P ，必然有 $P^T P = I$ ，例如

$$P = [e_1 \quad e_2 \quad e_3] = \begin{bmatrix} -\frac{2}{\sqrt{5}} & \frac{2}{3\sqrt{5}} & \frac{1}{3} \\ \frac{1}{\sqrt{5}} & \frac{4}{3\sqrt{5}} & \frac{2}{3} \\ 0 & \frac{5}{3\sqrt{5}} & -\frac{2}{3} \end{bmatrix}.$$

又因为 $P^{-1}P = I$ ，所以有 $P^T = P^{-1}$ 。此时，我们称 P 为**酉矩阵**(Unitary Matrix)。

- ▶ $P^T P = PP^T = I$
- ▶ 我们可以将矩阵 P 视为矩阵 A 对应的线性变化中出现的新坐标系，因为 P 是由标准正交基构成的。

奇异值分解

- ▶ 通过回顾矩阵对角化的知识我们知道，不是所有的矩阵 \mathbf{A} 都可以对角化，但一定可以进行分解！
- ▶ 奇异值分解（singular value decomposition, SVD）就是一种矩阵因子分解方法，它是方阵对角化的推广。

奇异值分解

- **（奇异值分解）** 矩阵的奇异值分解是指，将一个非零的 $m \times n$ 实矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 表示为以下三个实矩阵乘积形式的运算：

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T, \quad (1)$$

其中 \mathbf{U} 是 m 阶正交矩阵(orthogonal matrix)， \mathbf{V} 是 n 阶正交矩阵， $\mathbf{\Sigma}$ 是由降序排列的非负的对角线元素组成的 $m \times n$ 矩形对角矩阵(rectangular diagonal matrix)，满足

$$\begin{aligned} \mathbf{U}^T \mathbf{U} &= \mathbf{I}, \\ \mathbf{V}^T \mathbf{V} &= \mathbf{I}, \\ \mathbf{\Sigma} &= \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p), \\ \sigma_1 &\geq \sigma_2 \geq \dots \geq \sigma_p \geq 0, \\ p &= \min(m, n). \end{aligned}$$

奇异值分解

$$\begin{aligned} \mathbf{U}\mathbf{U}^T &= \mathbf{I}, \\ \mathbf{V}\mathbf{V}^T &= \mathbf{I}, \\ \mathbf{\Sigma} &= \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p), \\ \sigma_1 &\geq \sigma_2 \geq \dots \geq \sigma_p \geq 0, \\ p &= \min(m, n). \end{aligned}$$

- ▶ $\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 称为矩阵 \mathbf{A} 的奇异值分解 (singular value decomposition, SVD)
- ▶ σ_i 称为矩阵 \mathbf{A} 的奇异值 (singular value)
- ▶ \mathbf{U} 的列向量称为左奇异向量 (left singular vector)
- ▶ \mathbf{V} 的列向量称为右奇异向量 (right singular vector)

奇异值分解

► 例3: 给定一个 5×4 矩阵 A

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix}$$

它的奇异值分解结果为

$$U = \begin{bmatrix} 0 & 0 & \sqrt{0.2} & 0 & \sqrt{0.8} \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & \sqrt{0.8} & 0 & -\sqrt{0.2} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & \sqrt{5} & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad V^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

矩阵 Σ 是对角矩阵, 对角线外的元素都是0, 对角线上的元素非负, 按降序排列。矩阵 U 和 V 是正交矩阵, 它们与各自的转置矩阵相乘是单位矩阵, 即 $UU^T = I_5$, $VV^T = I_4$ 。

奇异值分解

- 矩阵的奇异值分解不是唯一的。在此例中如果选择 \mathbf{U} 为

$$\mathbf{U} = \begin{bmatrix} 0 & 0 & \sqrt{0.2} & \sqrt{0.4} & -\sqrt{0.4} \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sqrt{0.5} & \sqrt{0.5} \\ 0 & 0 & \sqrt{0.8} & -\sqrt{0.1} & \sqrt{0.1} \end{bmatrix}$$

而 Σ 与 \mathbf{V} 不变, 那么 $\mathbf{U}\Sigma\mathbf{V}^T$ 也是 \mathbf{A} 的一个奇异值分解。

奇异值分解的性质

- (1) 如果矩阵 \mathbf{A} 的奇异值分解为 $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$, 则以下关系成立:

$$\mathbf{A}^T \mathbf{A} = (\mathbf{U}\Sigma\mathbf{V}^T)^T (\mathbf{U}\Sigma\mathbf{V}^T) = \mathbf{V} (\Sigma^T \Sigma) \mathbf{V}^T$$

$$\mathbf{A}\mathbf{A}^T = (\mathbf{U}\Sigma\mathbf{V}^T) (\mathbf{U}\Sigma\mathbf{V}^T)^T = \mathbf{U} (\Sigma\Sigma^T) \mathbf{U}^T$$

\mathbf{V} 的列向量是 $\mathbf{A}^T \mathbf{A}$ 的特征向量, \mathbf{U} 的列向量是 $\mathbf{A}\mathbf{A}^T$ 的特征向量, Σ 中的奇异值是 $\mathbf{A}^T \mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 的特征值的平方根

奇异值分解的性质

- ▶ (2) 对于 $m > n$ 这种情况:

由 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 易知

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{\Sigma}$$

比较这一等式两端的第 j 列, 得到

$$\mathbf{A}\mathbf{v}_j = \sigma_j \mathbf{u}_j, \quad j = 1, 2, \dots, n$$

这是矩阵 \mathbf{A} 的右奇异向量和奇异值、左奇异向量的关系, 其中 \mathbf{u}_j 和 \mathbf{v}_j 分别是矩阵 \mathbf{U} 和 \mathbf{V} 的第 j 列

奇异值分解的性质

- 类似地，由

$$\mathbf{A}^T \mathbf{U} = \mathbf{V} \Sigma^T$$

得到

$$\begin{aligned}\mathbf{A}^T \mathbf{u}_j &= \sigma_j \mathbf{v}_j, \quad j = 1, 2, \dots, n \\ \mathbf{A}^T \mathbf{u}_j &= 0, \quad j = n+1, n+2, \dots, m\end{aligned}$$

这是矩阵 \mathbf{A} 的左奇异向量和奇异值、右奇异向量的关系

奇异值分解的性质

- ▶ (3) 矩阵 \mathbf{A} 的奇异值分解中, 奇异值 $\sigma_1, \sigma_2, \dots, \sigma_n$ 是唯一的, 而矩阵 \mathbf{U} 和 \mathbf{V} 不是唯一的
- ▶ (4) 矩阵 \mathbf{A} 和 Σ 的秩相等, 等于正奇异值 σ_i 的个数 r (包含重复的奇异值)

奇异值分解的性质

- ▶ (5) 矩阵 \mathbf{A} 的 r 个右奇异向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 构成 \mathbf{A}^T 的值域 $R(\mathbf{A}^T)$ 的一组标准正交基

矩阵 \mathbf{A} 的 $n - r$ 个右奇异向量 $\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n$ 构成 \mathbf{A} 的零空间 $N(\mathbf{A})$ 的一组标准正交基

矩阵 \mathbf{A} 的 r 个左奇异向量 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$ 构成值域 $R(\mathbf{A})$ 的一组标准正交基

矩阵 \mathbf{A} 的 $m - r$ 个左奇异向量 $\mathbf{u}_{r+1}, \mathbf{u}_{r+2}, \dots, \mathbf{u}_m$ 构成 \mathbf{A}^T 的零空间 $N(\mathbf{A}^T)$ 的一组标准正交基

奇异值分解的计算过程

- ▶ **目标：**对 $m \times n$ 矩阵 \mathbf{A} 进行奇异值分解
- ▶ **(1) 首先求 $\mathbf{A}^T \mathbf{A}$ 的特征值和特征向量**
计算对称矩阵

$$\mathbf{W} = \mathbf{A}^T \mathbf{A}$$

求解特征方程

$$(\mathbf{W} - \lambda \mathbf{I})\mathbf{x} = 0$$

得到特征值 λ_i ，并将特征值由大到小排列

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$$

将特征值 λ_i ($i = 1, 2, \cdots, n$) 代入特征方程求得对应的特征向量

奇异值分解的计算过程

► (2) 求 n 阶正交矩阵 V

将特征向量单位化, 得到单位特征向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 构成 n 阶正交矩阵 V :

$$V = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{bmatrix}$$

奇异值分解的计算过程

- (3) 求 $m \times n$ 对角矩阵 Σ
计算 A 的奇异值

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \dots, n$$

构造 $m \times n$ 矩形对角矩阵 Σ , 主对角线元素是奇异值, 其余元素是零,

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$$

奇异值分解的计算过程

- (4) 求 m 阶正交矩阵 U
对 A 的前 r 个正奇异值, 令

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r$$

得到

$$U_1 = [u_1 \quad u_2 \quad \cdots \quad u_r]$$

求 A^T 的零空间的一组标准正交基 $\{u_{r+1}, u_{r+2}, \dots, u_m\}$, 令

$$U_2 = [u_{r+1} \quad u_{r+2} \quad \cdots \quad u_m]$$

并令

$$U = [U_1 \quad U_2]$$

奇异值分解的计算过程

► (5) 得到奇异值分解

$$A = U\Sigma V^T$$

注：上述过程只是一种奇异值分解算法，实际中有很多矩阵奇异值分解的高效算法。


奇异值分解的计算过程

► 例4： 试求矩阵

$$\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{pmatrix}$$

的奇异值分解。

奇异值分解的几何解释



$$M = U \cdot \Sigma \cdot V^T$$

- 见李航《统计学习方法》（第2版）P279-280

紧奇异值分解与截断奇异值分解

- ▶ 上述给出的奇异值分解 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 又称为矩阵的完全奇异值分解 (full singular value decomposition)。
- ▶ 实际常用的是奇异值分解的紧凑形式和截断形式。
- ▶ 紧奇异值分解是与原始矩阵等秩的奇异值分解，截断奇异值分解是比原始矩阵低秩的奇异值分解。

紧奇异值分解与截断奇异值分解

- **紧奇异值分解:** 设有 $m \times n$ 实矩阵 \mathbf{A} , 其秩为 $\text{rank}(\mathbf{A}) = r$, $r \leq \min(m, n)$, 则称 $\mathbf{U}_r \Sigma_r \mathbf{V}_r^T$ 为 \mathbf{A} 的紧奇异值分解 (compact singular value decomposition), 即

$$\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^T,$$

其中 \mathbf{U}_r 是 $m \times r$ 矩阵, \mathbf{V}_r 是 $n \times r$ 矩阵, Σ_r 是 r 阶对角矩阵; 矩阵 \mathbf{U}_r 由完全奇异值分解中 \mathbf{U} 的前 r 列、矩阵 \mathbf{V}_r 由 \mathbf{V} 的前 r 列、矩阵 Σ_r 由 Σ 的前 r 个对角线元素得到。紧奇异值分解的对角矩阵 Σ_r 的秩与原始矩阵 \mathbf{A} 的秩相等。

紧奇异值分解与截断奇异值分解

► 例5: 由例3所给出的矩阵

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix}$$

的秩为3, \mathbf{A} 的紧奇异值分解是

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^T$$

其中

$$\mathbf{U}_r = \begin{bmatrix} 0 & 0 & \sqrt{0.2} \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \sqrt{0.8} \end{bmatrix}, \quad \mathbf{\Sigma}_r = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & \sqrt{5} \end{bmatrix}, \quad \mathbf{V}_r^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

紧奇异值分解与截断奇异值分解

- ▶ 在矩阵的奇异值分解中，只取最大的 k 个奇异值（ $k < r$ ， r 为矩阵的秩）对应的部分，就得到矩阵的截断奇异值分解。实际应用中提到矩阵的奇异值分解时，通常指截断奇异值分解。
- ▶ **截断奇异值分解：** 设 \mathbf{A} 为 $m \times n$ 实矩阵，其秩 $\text{rank}(\mathbf{A}) = r$ ，且 $0 < k < r$ ，则称 $\mathbf{U}_k \Sigma_k \mathbf{V}_k^T$ 为矩阵 \mathbf{A} 的截断奇异值分解（truncated singular value decomposition）

$$\mathbf{A} \approx \mathbf{U}_k \Sigma_k \mathbf{V}_k^T,$$

其中 \mathbf{U}_k 是 $m \times k$ 矩阵， \mathbf{V}_k 是 $n \times k$ 矩阵， Σ_k 是 k 阶对角矩阵；矩阵 \mathbf{U}_k 由完全奇异值分解中 \mathbf{U} 的前 k 列、矩阵 \mathbf{V}_k 由 \mathbf{V} 的前 k 列、矩阵 Σ_k 由 Σ 的前 k 个对角线元素得到。对角矩阵 Σ_k 的秩比原始矩阵 \mathbf{A} 的秩低。

紧奇异值分解与截断奇异值分解

► 例6: 由例3所给出的矩阵

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix}$$

的秩为3, 若取 $k = 2$ 则其截断奇异值分解是

$$\mathbf{A} \approx \mathbf{A}_2 = \mathbf{U}_2 \mathbf{\Sigma}_2 \mathbf{V}_2^T,$$

其中

$$\mathbf{U}_2 = \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{\Sigma}_2 = \begin{bmatrix} 4 & 0 \\ 0 & 3 \end{bmatrix}, \quad \mathbf{V}_2^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

这里的 $\mathbf{U}_2, \mathbf{V}_2$ 是例3中的 \mathbf{U} 和 \mathbf{V} 的前2列, $\mathbf{\Sigma}_2$ 是 $\mathbf{\Sigma}$ 的前2行前2列。

紧奇异值分解与截断奇异值分解

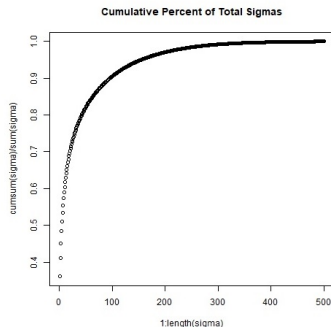
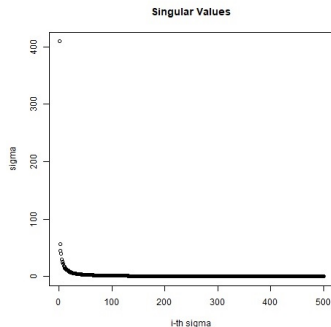
$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix} \quad \mathbf{A}_2 = \mathbf{U}_2 \mathbf{\Sigma}_2 \mathbf{V}_2^T = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

- \mathbf{A}_2 与 \mathbf{A} 比较, \mathbf{A} 的元素1和2在 \mathbf{A}_2 中均变成0。

紧奇异值分解与截断奇异值分解

- ▶ 在实际应用中，常常需要对矩阵的数据进行压缩，将其近似表示，奇异值分解提供了一种方法。
- ▶ 奇异值分解是在平方损失（弗罗贝尼乌斯范数）意义下对矩阵的最优近似。
 - ▶ 见李航《统计学习方法》（第2版）P287-290
- ▶ 紧奇异值分解对应着无损压缩，截断奇异值分解对应着有损压缩。
- ▶ 实际上，由于奇异值 σ_i 递减很快，所以 k 取很小值时， \mathbf{A}_k 也可以对 \mathbf{A} 有很好的近似。
- ▶ 因此，截断奇异值分解得到的低秩矩阵 \mathbf{A}_k 实现了对原矩阵 \mathbf{A} 的压缩（低秩矩阵近似）。

紧奇异值分解与截断奇异值分解



紧奇异值分解与截断奇异值分解


- ▶ 秩(rank)可以理解为矩阵所包含的信息的丰富程度。
- ▶ 例如在图像处理中，一张图片中的大部分成分是相似的，比如下面这张大草原的图片。



- ▶ 草原、蒙古包、人、马等是上图中包含的信息。
- ▶ 草原是由很多草组成的，而草是相似的，可以理解为草是草的复制品。
- ▶ 一张不错的图片的秩其实是比较低的，如果图像的秩比较高，往往是因为图像中的噪声比较严重。

奇异值分解的应用

► 应用1：数据压缩












► 原矩阵的大小: $m \times n$

► 经过奇异值分解后的三个矩阵的大小: $m \times k + k + n \times k$

奇异值分解的应用

► 应用2：图像压缩



奇异值分解的应用

► 应用3：潜在语义分析